

ejemplo: para los datos de los billetes del banco suizo, el vector de medias

$$\bar{x}_G(n) = \begin{pmatrix} 214.9 \\ 130.1 \\ 129.9 \\ 9.4 \\ 10.6 \\ 140.5 \end{pmatrix}$$

Los valores propios de $\hat{\Sigma}$, es decir, los elementos de la diagonal en la matriz $\hat{\Sigma}$ son

$$\begin{pmatrix} 2.985 \\ 0.931 \\ 0.242 \\ 0.194 \\ 0.085 \\ 0.035 \end{pmatrix}$$

Los vectores propios de $\hat{\Sigma}$, es decir las columnas g_1, \dots, g_p de \hat{g}

$$\hat{g} = \begin{pmatrix} -0.0437 & 0.011 & -0.326 & 0.562 & 0.753 & 0.098 \\ 0.112 & 0.071 & -0.259 & 0.455 & -0.347 & -0.767 \\ 0.139 & 0.066 & -0.345 & 0.415 & -0.535 & 0.632 \\ 0.768 & -0.563 & -0.218 & -0.186 & 0.100 & -0.022 \\ 0.202 & 0.659 & -0.557 & -0.451 & 0.102 & -0.035 \\ -0.579 & -0.489 & -0.592 & -0.258 & -0.085 & -0.046 \end{pmatrix}$$

Como ejemplo calculamos las componentes principales para los datos de los billetes del banco suizo.

La figura C nos muestra gráficos de dispersión para: (Y_1, Y_2) (Arriba a la izquierda), (Y_2, Y_3) (Arriba a la derecha), (Y_1, Y_3) (Abajo a la izquierda). Los caracteres "o" ó "+" corresponden a "verdaderos" ó "falsos". La gráfica abajo a la izquierda en la figura C, corresponde a los valores propios $\lambda_1, \lambda_2, \dots, \lambda_6$ de $\hat{\Sigma}$.

Ejercicio: Calcular de nuevo las componentes pero usando un reescalamiento de los datos \tilde{X} . Por ejemplo si se asume que las variables X_1, X_2, X_3 y X_6 fueron medidas en cms. y que X_4 y X_5 se quedan como estaban originalmente, o sea en escala de mm., esto sería equivalente a re-escalar $\tilde{X}_1 = X_1/10$; $\tilde{X}_2 = X_2/10$; $\tilde{X}_3 = \frac{X_3}{10}$ y $\tilde{X}_6 = X_6/10$ y usar la matriz de datos \tilde{X}

Este ejercicio tiene el fin de ilustrar que los gráficos pueden cambiar mucho. Dicho de otra forma: "LAS COMPONENTES PRINCIALES SON SENSIBLES A CAMBIOS DE ESCALA EN LAS VARIABLES".

Basta re-escalar una de las columnas en X para que los valores propios $\lambda_1, \dots, \lambda_p$ y los vectores propios g_1, g_2, \dots, g_p cambien. Veremos más adelante que una forma de evitar este problema es trabajar con la matriz de correlaciones R de los datos X .

Usando las primeras dos columnas de \mathbf{y}_j en la página 38, la primera y segunda componentes principales para los datos de billetes del banco suizo son

$$y_1 = 0.044x_1 + 0.112x_2 + 0.139x_3 + 0.768x_4 + 0.202x_5 - 0.579x_6$$

$$y_2 = 0.011x_1 + 0.071x_2 + 0.066x_3 - 0.563x_4 + 0.659x_5 - 0.489x_6$$

x_1 = longitud del billete.

x_2 = ancho del billete (a la izquierda).

x_3 = ancho del billete (a la derecha).

x_4 = distancia de la figura en el billete
al borde inferior del billete

x_5 = distancia de la figura en el billete
al borde superior del billete.

x_6 = longitud de la diagonal del billete

De forma que la primera componente y_1 , esencialmente corresponde a la diferencia entre el ancho del borde inferior del billete y la longitud de la diagonal

La segunda componente principal y_2 , corresponde a la diferencia entre el ancho del borde superior del billete y la suma de: el ancho del borde inferior y la longitud de la diagonal en los billetes.

Una medida que nos dice qué tan bien explican la variabilidad las primeras q componentes principales, está dada por

$$\psi_q = \frac{\sum_{j=1}^q \lambda_j}{\sum_{j=1}^P \lambda_j} = \frac{\sum_{j=1}^q \text{VAR}(Y_j)}{\sum_{j=1}^P \text{VAR}(Y_j)}$$

La figura D muestra una gráfica de las parejas ordenadas $(i, \frac{\lambda_i}{\sum_{j=1}^P \lambda_j}) ; i=1,2,\dots,6$.

Podemos darnos cuenta de que la 1^a componente principal explica un 66% de la variabilidad y las primeras dos componentes explican 88%. En algunos libros se sugiere seleccionar $i_0 \in \{1,2,\dots,6\}$ en donde la gráfica de

La figura D ⁽¹⁾ presenta un "codo" o se dobla. Este valor de i_0 es el número de componentes principales que se usarán para representar a los datos originales \mathbf{X} .

El siguiente teorema resultará de interés

TEOREMA Sea \mathbf{X} un vector aleatorio de dimensión $p \times 1$ tal que $E(\mathbf{X}) = \mathbf{M}$ y $VAR(\mathbf{X}) = \Sigma$. Sea \mathbf{Y} el vector de componentes principales de \mathbf{X} , entonces

$$(1) \text{ COV}(\mathbf{X}, \mathbf{Y}) = \Pi \Lambda,$$

donde Π es la matriz de dimensiones $p \times p$ cuyas columnas son los vectores propios de Σ (en la descomposición de Jordan de Σ) y Λ es una matriz diagonal (de dimensiones $p \times p$) que tiene los valores propios de Σ , $\lambda_1, \dots, \lambda_p$ como elementos de la diagonal.

(1) Scree Plot

(2) La correlación $\rho_{x_i y_j}$ entre la variable x_i y la componente principal y_j está dada por

$$\rho_{x_i y_j} = \gamma_{ij} \left(\frac{\lambda_j}{\delta x_i x_i} \right)^{1/2}, \quad \dots \text{ (rho)}$$

donde $\delta x_i^2 = \text{VAR}(x_i) = \Sigma_{ii}$ la entrada i,i de la matriz Σ y γ_{ij} es la entrada i,j de la matriz Γ .

Sea γ_i^1 la columna i en Γ , notemos que

$\sum_{j=1}^p \lambda_j \gamma_{ij}^2 = \gamma_i^1 \Delta \gamma_i^1 = \text{elemento } (i,i)$ de la matriz $\Gamma \Delta \Gamma^T = \Sigma$, entonces tenemos

$$\begin{aligned} \sum_{j=1}^p \rho_{x_i y_j}^2 &= \sum_{j=1}^p \gamma_{ij}^2 \frac{\lambda_j}{\Sigma_{ii}} = \frac{\sum_{j=1}^p \gamma_{ij}^2 \lambda_j}{\Sigma_{ii}} \\ &= \frac{\Sigma_{ii}}{\Sigma_{ii}} = 1. \end{aligned}$$

La anterior propiedad nos inspira a interpretar la "correlación" $\rho_{x_i y_j}^2$ como "la proporción de

de la varianza de la variable X_i explicada por la j -ésima componente principal Y_j ".

Siguiendo estas ideas, el porcentaje de la varianza de X_i explicado por las primeras q componentes principales Y_1, \dots, Y_q está dado por $\sum_{j=1}^q p_{X_i Y_j}^2$.

Como todas las cantidades mencionadas son poblacionales, necesitamos definir como calcular la correlación en la ecuación (ρ) para unos datos x_{11}, \dots, x_{nn} , esta correlación muestral está dada por

$$r_{X_i Y_j} = g_{ij} \left(\frac{l_j}{\hat{\Sigma}_{ii}} \right)^{1/2}.$$

Notemos que podemos argumentar como en (\star) pero con cantidades muestrales:

$\sum_{j=1}^p l_j g_{ij}^2 = g_i^T \hat{\Sigma}^{-1} g_i = \text{elemento } (i,i) \text{ de la matriz } g^T \hat{\Sigma}^{-1} g = \hat{\Sigma}_{ii} \quad (g_i = \text{columna } i \text{ en } g),$

de lo anterior tenemos que

$$\sum_{j=1}^P r_{x_i y_j}^2 = \sum_{j=1}^P g_{ij}^2 \left(\frac{f_j}{\hat{\Sigma}_{ii}} \right) = \frac{\sum_{j=1}^P g_{ij}^2 f_j}{\hat{\Sigma}_{ii}}$$

$$= \frac{\hat{\Sigma}_{ii}}{\hat{\Sigma}_{ii}} = 1.$$

nuevamente podemos interpretar $r_{x_i y_j}^2$ como "la proporción de la varianza de x_i explicada por la j -ésima componente principal y_j ".

Para incorporar este análisis en una gráfica, podemos graficar las parejas ordenadas $(r_{x_i y_1}, r_{x_i y_2})$; $i=1, 2, \dots, P$ en el plano. Dadas las observaciones arriba, tenemos que $r_{x_i y_1}^2 + r_{x_i y_2}^2 \leq 1$, de forma que las parejas $(r_{x_i y_1}, r_{x_i y_2})$ caen dentro del círculo de radio 1 en el plano. La figura E muestra estas parejas para

los datos de los billetes del banco Suizo.

Aquí observamos que para las variables X_4 , X_5 y X_6 las correspondientes parejas

$(r_{X_i, Y_1}, r_{X_i, Y_2})$ están más cercanas a la frontera del círculo unitario ($r_{X_i, Y_1}^2 + r_{X_i, Y_2}^2 \approx 1$), siguiendo el razonamiento antes descrito concluimos que Y_1 y Y_2 están muy correlacionados⁽¹⁾ con X_4 , X_5 y X_6 , pero no lo están al mismo grado con X_1 , X_2 y X_3 .

De la figura E, la correlación r_{X_6, Y_1} es negativa, la correlación r_{X_6, Y_2} es negativa y ambas son grandes, pero la correlación r_{X_4, Y_1} es positiva y la correlación r_{X_4, Y_2} es negativa, siendo ambas grandes. Esta información coincide con lo que tentamos

(1) La varianza de X_4 , X_5 y X_6 está bien explicada por Y_1 y Y_2 .

observado antes: el coeficiente de x_6 en la ecuación para y_1 es negativo y su magnitud grande (página 41), asimismo el coeficiente de x_4 es positivo (ecuación para y_1 , página 41) y su magnitud es grande. En otras palabras y_1 es básicamente determinada por la diferencia entre x_4 y x_6 .

En forma análoga r_{x_6,y_2} y r_{x_4,y_2} son negativas y grandes⁽¹⁾ (en comparación con r_{x_1,y_2} , r_{x_2,y_2} y r_{x_3,y_2}), así en la ecuación para y_2 en la página 41, los coeficientes de x_4 y x_6 son negativos y de magnitud mayor a los coeficientes de x_1 , x_2 y x_3 . Como r_{x_5,y_2} es positivo y su magnitud (en comparación con las de r_{x_1,y_2} , r_{x_2,y_2} y r_{x_3,y_2}) es grande

(1) Su magnitud es grande

observemos que en la ecuación para y_2 en la página 41 el coeficiente para x_5 es positivo y su magnitud es mayor que la de los coeficientes de x_1, x_2 y x_3 .

Se confirma entonces que y_2 queda explicada por la diferencia entre el ancho del borde superior del billete y la suma de: el ancho del borde inferior y la longitud de la diagonal en los billetes.

	$r_{xi}y_1$	$r_{xi}y_2$	$r_{xi}^2y_1 + r_{xi}^2y_2$
longitud x_1	-0.201	0.028	0.041
ancho izquierdo x_2	0.538	0.191	0.326
ancho derecho x_3	0.597	0.159	0.381
borde inf. x_4	0.921	-0.377	0.991
borde sup. x_5	0.435	0.794	0.820
diagonal x_6	-0.870	-0.410	0.926

El porcentaje de la varianza de x_1, x_2 y x_3 explicado por y_1 y y_2 es pequeño (las correlaciones $r_{xi}y_1$ y $r_{xi}y_2$ $i=1,2,3$ no tienen

magnitud grande. De aquí que los coeficientes de x_1 , x_2 y x_3 en las ecuaciones para y_1 y y_2 de la página 41 no son grandes (su magnitud no es grande) comparados con los coeficientes de x_4 , x_5 y x_6 .

Estas observaciones explican la figura C (panel superior a la izquierda), nosotros ya habíamos observado que x_6 muestra dos subconjuntos (verdaderos & falsos) en los billetes pero además en la figura D⁽¹⁾ se hace aparente que también x_5 es importante. Pero la discusión de arriba nos dice que y_1 y y_2 dependen de x_4 , x_5 y x_6 (no tanto de x_1 , x_2 y x_3)

(1) Página 19 de las notas sobre métodos gráficos. Diagramas de dispersión.

LA DISTRIBUCIÓN WISHART

La distribución Wishart juega un papel importante en la estimación de matrices de covarianza.

DEFINICIÓN:

Sea V^T una matriz de dimensiones $p \times p$, simétrica y positivo definida. Considerando V^T aleatoria, decimos que V^T tiene la distribución Wishart (no-singular, p -dimensional) con matriz de escala Σ y n grados de libertad ($p \leq n$), si la distribución conjunta de los elementos (distintos) de V^T es continua y con densidad dada por:

$$(W_i) \dots f(V^T; \Sigma, n) = \frac{c |V^T|^{(n-p-1)/2}}{|\Sigma|^{n/2}} e^{-\frac{1}{2} \text{tr}\{\Sigma^{-1} V^T\}} \mathbb{1}_B(V^T),$$

donde: $\Sigma > 0$, $B = \{A \in \mathbb{R}^{p \times p}: A > 0\}$,

$$\mathbb{1}_B(V^T) = \begin{cases} 1 & V^T \in B, \\ 0 & V^T \notin B. \end{cases} \quad \text{y } c \text{ es la constante}$$

definida por

$$C = \left\{ 2^{np/2} \pi^{\frac{1}{4}(p(p-1))} \prod_{j=1}^p \Gamma\left(\frac{n+1-j}{2}\right) \right\}^{-1}$$

$$\Gamma(t) = \int_0^\infty x^{t-1} e^{-x} dx. \quad \text{NOTACION} \\ V \sim \text{Wishart}_p(\Sigma, n)$$

Teorema: Sean $\mathbf{x}_1, \dots, \mathbf{x}_n$ vectores independientes de dimensión $p \times 1$ tales que $\mathbf{x}_i \sim N_p(0, \Sigma)$ $i=1, 2, \dots, n$, con $\Sigma > 0$. Sea \mathbf{X} la matriz de dimensiones $n \times p$ dada por

$$\mathbf{X} = \begin{pmatrix} \mathbf{x}_1' \\ \mathbf{x}_2' \\ \vdots \\ \mathbf{x}_n' \end{pmatrix}; \quad p \leq n.$$

Sea $V = \mathbf{X}' \mathbf{X}$. Entonces $V > 0$

y $V \sim \text{Wishart}_p(\Sigma, n)$.

La demostración se puede encontrar en Cramer, H. (1946) "Mathematical Methods of Statistics" p. 405, Princeton University Press.

ejemplo: Supóngase $\rho=1$, entonces tenemos u.a.

$$X_1, X_2, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(0, \sigma^2)$$

$$\mathbf{X} = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_n \end{pmatrix} \quad \mathbf{X}' \mathbf{X} = \sum_{i=1}^n X_i^2$$

y de acuerdo al Teorema si $V = \sum_{i=1}^n X_i^2$, su densidad

$$\begin{aligned} \text{es } f_V(v; \sigma^2, n) &= \underbrace{\frac{1}{2^{n/2} \Gamma(\frac{n}{2})}}_{C} \frac{v^{n/2}}{\sigma^{n/2}} e^{-\frac{v}{2\sigma^2}} \mathbb{I}_{(0, \infty)}(v) \\ &= \frac{\left(\frac{1}{2\sigma}\right)^{n/2}}{\Gamma(n/2)} v^{n/2-1} e^{-v/2\sigma^2} \cdot \mathbb{I}_{(0, \infty)}(v) \end{aligned}$$

es decir V tiene distribución

$$\text{Gamma} \left(\alpha = \frac{n}{2}; \beta = \frac{1}{2\sigma^2} \right) \quad (= \text{Wishart}_1(\sigma^2, n))$$

"La distribución Wishart_p(Σ, n) representa una generalización de la distribución Gamma a "múltiples dimensiones"

$$\text{siguiente: } X \sim \mathcal{N}(0, \sigma^2 I_p)$$

De hecho si $X \sim \mathcal{N}(0, \sigma^2 I_p)$ entonces V tiene la misma distribución que $\sigma^2 X$, entonces

podemos re-escribir el párrafo anterior como
 "La distribución Wishart_p(Σ, n) representa una generalización a p dimensiones de distribuciones proporcionales a la distribución $\chi^2_{(n)}$ ".
 $(p=1 \Rightarrow \frac{V}{\sigma^2} \sim \chi^2_{(n)})$

Nota Aunque hablamos de la distribución de una matriz en la definición (W_i), nos referimos a la distribución conjunta de los elementos de la matriz simétrica V_i

$$(p) \dots V_i = \begin{pmatrix} v_{11} & v_{21} & \cdots & v_{p1} \\ v_{21} & v_{22} & \cdots & v_{p2} \\ \vdots & \vdots & & \\ v_{p1} & v_{p2} & \cdots & v_{pp} \end{pmatrix},$$

pero como V_i es simétrica, en realidad se está definiendo una distribución para el vector $p(p+1)/2$ -dimensional

$(\alpha) \dots (v_{11}, v_{21}, \dots, v_{p1}, v_{22}, v_{32}, \dots, v_{p2}, \dots, v_{pp})^T$,
 el conjunto B en la definición (W_i), es el conjunto de matrices simétricas de dimensión $p \times p$ tales que son positivo definidas,

pero debido a esta observación, podemos escribir \mathcal{B} como el conjunto de vectores $p(p+1)/2$ dimensionales (como en (d)) que hacen que ∇ en (β) sea positivo definido.

El teorema establece que si las observaciones x_1, \dots, x_n provienen de una distribución $N_p(\mu, \Sigma)$, $\text{cov}(x_i, x_j) = E(x_i \cdot x_j)$ ya que $\mu = 0$, entonces

$$n \hat{\Sigma} = \mathbf{x}' \mathbf{x}$$

es una observación ó realización de la v.a. matricial

$$\mathbf{x}' \mathbf{x} \sim \text{Wishart}_p(\Sigma, n)$$

Teorema : Sean x_1, \dots, x_n vectores de dimensión $p \times 1$, independientes y con distribución $N_p(\mu, \Sigma)$; $\Sigma > 0$. Sean $\bar{x}_{(n)}$ el vector

$$\bar{\mathbf{x}}_{(n)} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i = \begin{pmatrix} \frac{1}{n} \sum_{i=1}^n x_{i1} \\ \frac{1}{n} \sum_{i=1}^n x_{i2} \\ \vdots \\ \frac{1}{n} \sum_{i=1}^n x_{ip} \end{pmatrix} = \begin{pmatrix} \bar{x}_{\cdot 1} \\ \bar{x}_{\cdot 2} \\ \vdots \\ \bar{x}_{\cdot p} \end{pmatrix}$$

$$\begin{aligned} y \quad V &= \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}_{(n)}) (\mathbf{x}_i - \bar{\mathbf{x}}_{(n)})' \\ &= \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i' - n \bar{\mathbf{x}}_{(n)} \bar{\mathbf{x}}_{(n)}' \\ &\stackrel{(1)}{=} \mathbf{x}' \mathbf{x} - \frac{1}{n} \mathbf{x}' \mathbf{1}_n \mathbf{1}_n' \mathbf{x} \\ &= \mathbf{x}' (\mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n') \mathbf{x} \\ &= \mathbf{x}' P(\mathbf{x}). \end{aligned}$$

Entonces si $p+1 \leq n$,

(2)

$$V > 0 \quad y \quad V \sim \text{Wishart}_p(\Sigma, n-1).$$

Como consecuencia de este resultado, si $\hat{\Sigma}$ es

$$(1) \quad \bar{\mathbf{x}}_{(n)} = \frac{1}{n} \mathbf{x}' \mathbf{1}_n = \frac{1}{n} \begin{pmatrix} x_{11} & x_{21} & \cdots & x_{n1} \\ x_{12} & x_{22} & \cdots & x_{n2} \\ \vdots & & & \\ x_{1p} & x_{2p} & \cdots & x_{np} \end{pmatrix} \begin{pmatrix} 1 \\ \vdots \\ 1 \end{pmatrix}$$

(2) véase Press, J. (2005). "Applied Multivariate Analysis". Dover

la matriz de covarianzas estimada a partir de los datos x_1, \dots, x_n

$$\begin{aligned}\hat{\Sigma} &= \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x}_n)(x_i - \bar{x}_n)^T \\ &= \frac{1}{n} \mathbf{x}' H \mathbf{x},\end{aligned}$$

entonces $n \hat{\Sigma}$ es una realización de la v.d. matricial $\mathbf{x}' H \mathbf{x} \sim \text{Wishart}_p(\Sigma, n-1)$.

Recordemos que para n pequeña suele utilizarse el estimador insesgado (corrección de Bessel) para Σ

$$\hat{\Sigma}^{(c)} = \frac{n}{n-1} \hat{\Sigma} = \frac{1}{n-1} \mathbf{x}' H \mathbf{x}$$

De la discusión anterior

$(n-1) \hat{\Sigma}^{(c)}$ es una realización de $\mathbf{x}' H \mathbf{x} \sim \text{Wishart}_p(\Sigma, n-1)$.

Por ejemplo si $p=1$ $\hat{\Sigma}^{(c)} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 (1 \times 1)$

$(n-1) \hat{\Sigma}^{(c)} \sim \text{Wishart}_1(\Sigma, n-1)$

ó bien $\frac{(n-1) \hat{\Sigma}^{(c)}}{\Sigma} \sim \chi_{(n-1)}^2$

Teorema (Transformaciones de Estadísticas asintóticamente Normales) TEAN

$$\text{Si } \sqrt{m}(\bar{T}_m - \mu) \xrightarrow[m \rightarrow \infty]{d} N_p(0, \Sigma)$$

y si $\forall i=1,2,\dots,s$ $f_i: \mathbb{R}^p \rightarrow \mathbb{R}$ definen

$$f = \begin{pmatrix} f_1 \\ \vdots \\ f_s \end{pmatrix}: \mathbb{R}^p \rightarrow \mathbb{R}^s$$

una transformación diferenciable en $\mu \in \mathbb{R}^p$, entonces $f(\bar{T}_m)$ es asintóticamente Normal con media $f(\mu)$ y matriz de covarianzas

$$D' \Sigma D :$$

$$\sqrt{m} (f(\bar{T}_m) - f(\mu)) \xrightarrow[m \rightarrow \infty]{d} N_s(0, D' \Sigma D),$$

donde

$$D_{ij} = \left. \frac{\partial f_j}{\partial T_i} (\tau) \right|_{\tau=\mu} \quad \begin{array}{l} i=1,2,\dots,p \\ j=1,2,\dots,s \end{array}$$

D es la matriz, de dimensiones $p \times s$, de derivadas parciales

Teorema (distribución asintótica de los valores propios muestrales l_1, \dots, l_p de $\hat{\Sigma}$) DAUP

Sea $\Sigma > 0$ con valores propios diferentes

Sea $n \mathbf{U} \sim \text{Wishart}_p(\Sigma, m=n-1)$ y

supóngase que las descomposiciones de Jordan

para Σ y \mathbf{U} son $\Sigma = \Gamma \Delta \Gamma'$ y

$\mathbf{U} = \Gamma \mathbf{D} \Gamma'$. Entonces

$$\sqrt{n-1} (\mathbf{l} - \boldsymbol{\lambda}) \xrightarrow[n \rightarrow \infty]{d} N_p(0, 2\Delta^2)$$

donde $\mathbf{l} = (l_1, \dots, l_p)'$ y $\boldsymbol{\lambda} = (\lambda_1, \dots, \lambda_p)'$

son las diagonales de \mathbf{I} y Δ .

Sea $s=1$ y $f=f_1 : \mathbb{R}^P \rightarrow \mathbb{R}$

dado por

$$f(\tau_1, \dots, \tau_p) = \frac{\tau_1 + \dots + \tau_q}{\tau_1 + \dots + \tau_p}, \quad (q \leq p).$$

$$\text{si } \alpha = \begin{pmatrix} \lambda_1 \\ \lambda_2 \\ \vdots \\ \lambda_p \end{pmatrix}, \quad f(\lambda_1, \dots, \lambda_p) = f(\alpha)$$

$$\ell = \begin{pmatrix} \ell_1 \\ \vdots \\ \ell_p \end{pmatrix}, \quad f(\ell) = \hat{\psi}_q. \quad = \hat{\psi}_q \text{ y para}$$

Para cada $i=1, 2, \dots, q$

$$\begin{aligned} \frac{\partial f(\tau)}{\partial \tau_i} &= \frac{(\tau_1 + \dots + \tau_p) \cdot 1 - (\tau_1 + \dots + \tau_q) \cdot 1}{(\tau_1 + \dots + \tau_p)^2} \\ &= \frac{1 - \frac{\tau_1 + \dots + \tau_q}{\tau_1 + \dots + \tau_p}}{(\tau_1 + \dots + \tau_p)}. \end{aligned}$$

y para cada $i=q+1, q+2, \dots, p$

$$\begin{aligned} \frac{\partial f(\tau)}{\partial \tau_i} &= \frac{(\tau_1 + \dots + \tau_p) \cdot 0 - (\tau_1 + \dots + \tau_q) \cdot 1}{(\tau_1 + \dots + \tau_p)^2} \\ &= \frac{-(\tau_1 + \dots + \tau_q)}{(\tau_1 + \dots + \tau_p)^2}. \end{aligned}$$

nota si $i=1, 2, \dots, q$ y como $\Pi = \Sigma$

$$\left. \frac{\partial f(\pi)}{\partial \pi_i} \right|_{\pi=\Sigma} = -\frac{1-\psi_q}{\text{tr}(\Sigma)} .$$

Por otra parte, si $i=q+1, \dots, P$

$$\left. \frac{\partial f(\pi)}{\partial \pi_i} \right|_{\pi=\Sigma} = -\frac{-\psi_q}{\text{tr}(\Sigma)} .$$

Considerando que $\Sigma = 2\Lambda^2 = 2 \begin{pmatrix} \lambda_1^2 & 0 & \cdots & 0 \\ 0 & \lambda_2^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \lambda_P^2 \\ 0 & 0 & \cdots & 0 \end{pmatrix}$

$$\begin{aligned} D' &= \left(\left. \frac{\partial f(\pi)}{\partial \pi_1} \right|_{\pi=\Sigma}, \dots, \left. \frac{\partial f(\pi)}{\partial \pi_P} \right|_{\pi=\Sigma} \right) \\ &= \left(\frac{1-\psi_q}{\text{tr}(\Sigma)}, \dots, \frac{1-\psi_q}{\text{tr}(\Sigma)}, -\frac{\psi_q}{\text{tr}(\Sigma)}, \dots, -\frac{\psi_q}{\text{tr}(\Sigma)} \right) \\ &= \frac{1}{\text{tr}(\Sigma)} (1-\psi_q, \dots, 1-\psi_q, -\psi_q, \dots, -\psi_q) . \end{aligned}$$

De forma que $D'^T \Sigma D =$

$$\frac{2}{(\text{tr}(\Sigma))^2} (1-\psi_q, \dots, 1-\psi_q, -\psi_q, \dots, -\psi_q) \begin{pmatrix} \lambda_1^2 & 0 & \cdots & 0 \\ 0 & \lambda_2^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \lambda_P^2 \\ 0 & 0 & \cdots & 0 \end{pmatrix} \begin{pmatrix} 1-\psi_q \\ \vdots \\ 1-\psi_q \\ -\psi_q \\ \vdots \\ -\psi_q \end{pmatrix}$$

$$\mathcal{D}' \otimes \mathcal{D} = \left[(1-\psi_q)^2 \lambda_1^2 + \dots + (1-\psi_q)^2 \lambda_q^2 + \psi_q^2 \lambda_{q+1}^2 + \dots + \psi_q^2 \lambda_p^2 \right]$$

$$\times \frac{2}{(\text{tr}(\Sigma))^2}$$

$$= \frac{2}{(\text{tr}(\Sigma))^2} \times \left[(1-\psi_q)^2 (\lambda_1^2 + \dots + \lambda_q^2) + \psi_q^2 (\lambda_{q+1}^2 + \dots + \lambda_p^2) \right]$$

$$= \frac{2}{(\text{tr}(\Sigma))^2} \times \left[\psi_q^2 (\lambda_1^2 + \dots + \lambda_p^2) - 2\psi_q (\lambda_1^2 + \dots + \lambda_q^2) + (\lambda_1^2 + \dots + \lambda_q^2) \right].$$

$$\text{Sea } \beta = \frac{\lambda_1^2 + \dots + \lambda_q^2}{\lambda_1^2 + \dots + \lambda_p^2}, \quad \lambda_1^2 + \dots + \lambda_q^2 = \beta (\lambda_1^2 + \dots + \lambda_p^2),$$

entonces

$$\mathcal{D}' \otimes \mathcal{D} = \frac{2 (\lambda_1^2 + \dots + \lambda_p^2)}{(\text{tr}(\Sigma))^2} \times [\psi_q^2 - 2\psi_q \beta + \beta].$$

Así, para encontrar la distribución asintótica

de $\hat{\psi}_q = f(l_1, \dots, l_p)$, usamos los teoremas

DAVP y TEAN para obtener el siguiente

TEOREMA (Distribución Asintótica de $\hat{\psi}_q$)

Para $q \leq p$, Sean $\psi_q = \frac{\lambda_1 + \dots + \lambda_q}{\lambda_1 + \dots + \lambda_p}$ y $\hat{\psi}_q = \frac{l_1 + \dots + l_q}{l_1 + \dots + l_p}$

La proporción de la variabilidad de los datos explicada por las primeras q componentes principales y su estimación muestral. Entonces, cuando el tamaño de muestra n crece a ∞

$$\sqrt{n-1} (\hat{\Psi}_q - \Psi_q) \xrightarrow{d} N_1(0, w^2), \quad \dots (u)$$

donde

$$w^2 = \frac{2(\lambda_1^2 + \dots + \lambda_p^2)}{(\text{tr } (\Sigma))^2} \times \left\{ \Psi_q^2 - 2\Psi_q \beta + \beta \right\}$$

$$\text{y } \beta = \frac{\lambda_1^2 + \dots + \lambda_q^2}{\lambda_1^2 + \dots + \lambda_p^2}.$$

Con este resultado, podemos construir un intervalo de confianza a nivel $(1-\alpha) \times 100\%$. para el verdadero valor de la proporción Ψ_q .

Usando (u); si n es suficientemente grande

$$P \left(\left| \frac{\hat{\Psi}_q - \Psi_q}{w_{\sqrt{n-1}}} \right| \leq Z_{1-\alpha/2} \right) \xrightarrow{\text{aprox}} 1-\alpha, \quad \dots (v)$$

donde $\alpha \in (0,1)$ es un tamaño de error (nivel de significancia) y $Z_{1-\alpha/2}$ es el

cuantil de una distribución $N(0,1)$ correspondiente a probabilidad $1-\alpha/2$:

$$\text{aprox} \quad \int_{-\infty}^{Z_{1-\alpha/2}} \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x^2} dx = 1 - \alpha/2 .$$

$$\begin{aligned} 1 - \alpha &\approx P\left(\left|\frac{\hat{\Psi}_q - \Psi_q}{w/\sqrt{n-1}}\right| \leq Z_{1-\alpha/2}\right) \\ &= P\left(-Z_{1-\alpha/2} \leq \frac{\hat{\Psi}_q - \Psi_q}{w/\sqrt{n-1}} \leq Z_{1-\alpha/2}\right) \\ &= P\left(-Z_{1-\alpha/2} \leq \frac{\Psi_q - \hat{\Psi}_q}{w/\sqrt{n-1}} \leq Z_{1-\alpha/2}\right) \\ &= P\left(\hat{\Psi}_q - w/\sqrt{n-1} \times Z_{1-\alpha/2} \leq \Psi_q \leq \hat{\Psi}_q + w/\sqrt{n-1} \times Z_{1-\alpha/2}\right). \end{aligned}$$

Entonces, a nivel $(1-\alpha) \times 100\%$. de confianza

Ψ_q debe estar en el intervalo

$$\left(\hat{\Psi}_q - w/\sqrt{n-1} \times Z_{1-\alpha/2}, \hat{\Psi}_q + w/\sqrt{n-1} \times Z_{1-\alpha/2}\right).$$

cuantil de una distribución $N(0,1)$ correspondiente a probabilidad $1-\alpha/2$:

$$\text{aprox} \quad \int_{-\infty}^{Z_{1-\alpha/2}} \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}x^2} dx = 1 - \alpha/2 .$$

$$\begin{aligned} 1 - \alpha &\approx \mathbb{P}\left(\left|\frac{\hat{\psi}_q - \psi_q}{w/\sqrt{n-1}}\right| \leq Z_{1-\alpha/2}\right) \\ &= \mathbb{P}\left(-Z_{1-\alpha/2} \leq \frac{\hat{\psi}_q - \psi_q}{w/\sqrt{n-1}} \leq Z_{1-\alpha/2}\right) \\ &= \mathbb{P}\left(-Z_{1-\alpha/2} \leq \frac{\psi_q - \hat{\psi}_q}{w/\sqrt{n-1}} \leq Z_{1-\alpha/2}\right) \\ &= \mathbb{P}\left(\hat{\psi}_q - w/\sqrt{n-1} \times Z_{1-\alpha/2} \leq \psi_q \leq \hat{\psi}_q + w/\sqrt{n-1} \times Z_{1-\alpha/2}\right). \end{aligned}$$

Entonces, a nivel $(1-\alpha) \times 100\%$ de confianza ψ_q debe estar en el intervalo

$$\left(\hat{\psi}_q - w/\sqrt{n-1} \times Z_{1-\alpha/2}, \hat{\psi}_q + w/\sqrt{n-1} \times Z_{1-\alpha/2}\right).$$

Para los datos de billetes del banco suizo,

sabemos que $\hat{\psi}_1 = \frac{l_1}{l_1 + l_2 + \dots + l_6} = 0.67$.

Supóngase que quisieramos probar la hipótesis

$$(h) \cdots \left\{ \begin{array}{l} H_0: \Psi_1 = 0.75 \\ \text{vs.} \\ H_1: \text{No } H_0 \end{array} \right.$$

Una forma de llevar a cabo la prueba de hipótesis es usando intervalos de confianza

$$\hat{\beta} = \frac{l_1^2}{l_1^2 + \dots + l_6^2} = \frac{(2.985)^2}{(2.985)^2 + (0.931)^2 + \dots + (0.035)^2}$$

$$= 0.902 .$$

$$\begin{aligned} \lambda_1^2 + \lambda_2^2 + \dots + \lambda_6^2 &= \text{tr}(\Lambda^2) = \text{tr}(\Lambda^2 \Gamma' \Gamma) \\ &= \text{tr}(\Gamma \Lambda^2 \Gamma') \\ &= \text{tr}(\Gamma \Lambda \Gamma' \Gamma \Lambda \Gamma') = \text{tr}(\Sigma \Sigma') \\ &= \text{tr}(\hat{\Sigma}^2) \end{aligned}$$

$$\begin{aligned} \text{Se puede estimar con } \text{tr}(\hat{\Sigma}^2) &= \sum_{j=1}^6 l_j^2 \\ &= 9.883 \end{aligned}$$

$$\begin{aligned} \text{tr}(\Sigma) \text{ se puede estimar con } \text{tr}(\hat{\Sigma}) \\ &= \text{tr}(g_1 \Gamma g_1') = \text{tr}(\Gamma g_1' g_1) = \text{tr}(\Gamma) \\ &= l_1 + \dots + l_6 = 4.472 \end{aligned}$$

De manera que w en la ecuación (u), página 63 se puede estimar por

$$\hat{w}^2 = \frac{2 \operatorname{tr}(\hat{\Sigma}^2)}{[\operatorname{tr}(\hat{\Sigma})]^2} (\hat{\psi}_1^2 - 2\hat{\psi}_1\hat{\beta} + \hat{\beta}^2)$$

$$= \frac{2(9.883)}{(4.472)^2} [(0.668)^2 - 2(0.668)(0.902) + 0.902]$$

$$= 0.142.$$

Entonces, a nivel $0.95 \times 100\% \quad (\alpha = 0.05)$ de significancia un intervalo (aproximado) para ψ_1 es (véase página 64)

$$(0.668 - \sqrt{\frac{0.142}{199}} \times 1.96, 0.668 + \sqrt{\frac{0.142}{199}} \times 1.96)$$

$$= (0.615, 0.720),$$

el cual no contiene el valor de 0.75, por tanto rechazamos H_0 en (h).

ANALISIS DE COMPONENTES PRINCIPALES NORMALIZADO

Como se mencionó antes, las componentes principales son sensibles a cambios de escala en las variables, de esta forma al re-escalor alguna de las variables bajo estudio los resultados pueden cambiar.

Por otra parte, uno de los objetivos en el análisis de componentes principales es encontrar las direcciones en \mathbb{R}^P , para las cuales los datos presenten mayor variabilidad. Sin embargo si los datos originales presenten heterogeneidad con respecto a sus variables, por ejemplo si la escala de la variable X_i es en kilogramos y la escala de X_j este en dólares, entonces "la dirección en \mathbb{R}^P para la que los datos presenten mayor variabilidad" podría originarse por la heterogeneidad en las escalas y no debido a la naturaleza de los datos.

Para evitar estos problemas se utiliza una estandarización de las variables en el vector \bar{x}_G , a saber